


PÓS TECH

Estratégias de Machine Learning para Aumentar a Eficiência e a Inovação Empresarial



Por que tantas empresas investem em IA e não conseguem resultados?

Felipe Rafael de Souza

16 de julho de 2026 • 19h30–21h00



Quem fala com vocês



Felipe Rafael de Souza

Cientista de Dados & Professor



Pesquisa

Cientista da computação, mestre em Modelagem Computacional (UFJF) - pesquisa em aprendizado por reforço e modelos generativos antes do boom da IA generativa.



Prática

Cofundador da Requalify.ai e da Evakub: IA aplicada em pesquisa qualitativa, visão computacional, saúde e problemas multimodais. Projetos de âmbito nacional em saúde mental.



Ensino e inovação

Consultor e Professor em projetos de capacitação e inovação tecnológica (PUC-Rio), com foco em IA generativa, LLMs e automação.

Nunca se investiu tanto. Nunca se falhou tanto.

US\$ 30-40 bi

investidos em IA generativa corporativa

MIT, "The GenAI Divide" (2025)

95%

dos pilotos corporativos sem impacto mensurável no resultado (Profit and Loss)

MIT NANDA, análise de 300 implementações

> 40%

dos projetos de IA agêntica serão cancelados até o fim de 2027

Gartner (2025): custos, valor incerto, risco

Por que empresas com dinheiro e dados falham em ML?



Eficiência

Otimizar o que já existe: mapa de oportunidades, dados antes de modelos, quando NÃO usar ML.



A ponte

Eficiência financeira inovação: build vs. buy vs. fine-tune e por que acurácia não é ROI.



Inovação

Criar o novo com responsabilidade: riscos, regulação, governança e um roadmap prático.



A realidade de muitas iniciativas corporativas...

Eficiência

Otimizar o que já existe

Foco em processos que a empresa já domina para obter ganhos rápidos e consistentes.



**Menos
Custo**



**Menos
Tempo**



**Menos
Erro**



Conheçam o Grupo Horizonte

Uma rede varejista fictícia



Varejo de médio porte

82 lojas em 4 estados • e-commerce próprio • ~6.000 funcionários



Dados espalhados em 6 sistemas que não conversam entre si



Diretoria deslumbrada: “precisamos colocar IA em tudo, já”



Orçamento finito: R\$ 2 milhões para “o projeto de IA”



Um único cientista de dados que foi contratado mês passado

A cada decisão do Horizonte,
vamos ver uma empresa real que
enfrentou algo parecido e o que
aconteceu.

Problema de negócio → Família de solução



Prever demanda, churn, inadimplência



Modelos supervisionados clássicos (o “arroz com feijão” que paga a conta)



Descobrir segmentos e padrões escondidos



Aprendizado não supervisionado: clusterização, detecção de anomalias



Documentos, atendimento, conhecimento interno



LLMs + RAG: busca e geração ancoradas nos dados da empresa



Operações físicas: loja, estoque, fábrica



Visão computacional: auditoria de estoque, contagem, inspeção



Rotas, preços, alocação de recursos



Otimização + ML: pesquisa operacional

Antes da técnica, 5 perguntas sobre o problema

1

Que SAÍDA o problema pede?

Número → regressão • categoria → classificação • grupos → clusterização • texto/conversa → LLM • agir no mundo → otimização/RL

2

Tenho dados? Rotulados?

Sem rótulos: não supervisionado ou colete primeiro. Se pouco dado: modelo pronto (API) ou regra

3

Qual o custo de errar?

Alto: humano no processo, limiares conservadores, projeto piloto pequeno

4

Preciso explicar a decisão?

Crédito, saúde, jurídico: modelos interpretáveis tendem a ser melhor opção (modelos caixa-preta pode ser vetada por lei ou auditoria)

5

A regra já é conhecida e estável?

Se sim: if/else: você não tem um problema de ML!

Você é o CTO do Horizonte. Por onde começar?



A

Chatbot de atendimento ao cliente

É o que a diretoria quer mostrar no LinkedIn



B

Previsão de demanda e estoque

Menos ruptura e menos capital parado



C

Automação fiscal e de back-office

Não aparece de cara



D

Câmeras inteligentes nos corredores da loja

Auditoria de loja em tempo real

Respondam com A, B, C ou D no chat →

Todo mundo quer o topo. Quase ninguém tem a base.



O custo do dado ruim

- Modelo excelente + dado errado = decisão errada em escala
- LGPD como requisito de projeto, não obstáculo posterior
- Regra prática: se o relatório mensal ainda é uma briga, a IA generativa pode esperar

Klarna: a eficiência que saiu cara



2024

O anúncio triunfal

IA “faz o trabalho de 700 agentes”: 2,3 mi de conversas no 1º mês; resolução de 11 min → 2 min; economia projetada de US\$ 40 mi.

2025

A conta chega

Satisfação cai nos casos complexos, reclamações e recontatos sobem. O dashboard médio seguia bonito.

2025–26

“Fomos longe demais”

CEO admite o erro, empresa recontrata humanos em modelo híbrido. Custo de reversão supera a economia projetada.

O dashboard mostrava o comportamento médio média. Casos complexos, onde o cliente precisa de cuidado humano, destruiu a marca.

McDonald's + IBM: o fracasso que foi um sucesso

O experimento (2021–2024)

- Pedidos por voz no drive-thru, com IA da IBM
- Ruído, sotaques e vozes sobrepostas confundiam o sistema: bacon no sorvete, nove chás doces e vídeos virais no TikTok
- Encerrado em julho de 2024, após 3 anos de teste

Por que foi um sucesso?

- O teste ficou restrito a um piloto controlado
- Fracasso barato = aprendizado; fracasso escalado = catástrofe
- A empresa saiu com clareza sobre o que a tecnologia ainda não faz

100

lojas no piloto...

de 40.000+

no mundo. Risco contido por desenho.



Quando **NÃO** usar machine learning

Quem vende IA dizendo “aqui não precisa de IA” ganha credibilidade!!!



A regra é conhecida e estável

Um if/else bem escrito não alucina, não sofre drift e custa quase zero para manter



A pergunta já tem resposta nos dados

Um SQL e um bom dashboard resolvem, sem GPU, sem MLOps



O processo está quebrado

Automatizar o caos só produz caos mais rápido: redesenhe o processo primeiro



Poucos dados + decisão crítica

Julgamento humano com checklist supera modelo mal alimentado



Data

+

Machine Learning

=



Data

+

Artificial Intelligence

=



Data

+

Generative AI

=



Data

+

Agentic AI

=



A ponte

Eficiência bem feita financia, alimenta e habilita a inovação.




O ciclo: eficiência financeira inovação



Onde o ciclo quebra: pular direto para o passo 3 sem os passos 1 e 2 ou ficar preso no passo 1 para sempre.

Build, buy ou fine-tune?



Usar API de modelo de fundação

- Rápido para começar; sem infra própria
- Custo por uso; pode explodir em escala
- Dados saem do seu perímetro: avalie contrato e LGPD
- Risco de lock-in no fornecedor

Ideal para: começar, validar, volume baixo/médio

Fine-tuning de modelo aberto

- Modelo menor especializado pode superar gigante genérico
- Dados ficam em casa: privacidade e compliance
- Exige dados de qualidade + equipe + MLOps
- Custo fixo maior, custo marginal menor

Ideal para: domínio específico, escala, dados sensíveis

Treinar do zero


- Raríssimo fora de big techs e labs
- Custo de milhões a bilhões
- Só faz sentido com dado e caso de uso únicos no mundo
- Para 99% das empresas: não é por aqui

MIT (2025): ferramentas de fornecedores externos têm 2x a taxa de sucesso das construções internas.

Acurácia não é ROI

O modelo enxerga

- Precisão, recall, F1
- AUC, RMSE, perplexidade
- Latência e custo por inferência



O negócio enxerga

- Receita incremental e perda evitada
- Horas economizadas por equipe
- Satisfação, churn, tempo de ciclo



Antes de qualquer modelo, duas perguntas de baseline: *quanto custa não fazer nada? E quanto um modelo simples (ou uma regra) já resolve?*



Zillow: o modelo certo no mundo errado

US\$ 500 mi+

em **perdas** e baixas contábeis (2021)

~7.000

casas compradas acima do valor de
revenda

25%

da força de trabalho demitida no
encerramento

O que aconteceu

- O Zillow Offers usava o algoritmo de precificação para comprar casas, reformar e revender
- O mercado esfriou e o modelo, alimentado com dados defasados (semanas de idade) para decisões quase em tempo real, continuou comprando caro
- Drift: a distribuição do mundo mudou; o modelo, treinado no mundo antigo, não percebeu

Lição: modelo em produção sem monitoramento não é ativo, é passivo com juros.

Inovação



Os pilares da inovação corporativa



01

**Ter diferencial
estratégico**



02

Gerar valor real



03

**Explorar novas
ideias**



04

**Atender
necessidades
de mercado**



05

**Aumentar
competitividade**

Inovação joga outro jogo

Eficiência

Métrica clara de custo/tempo

Risco baixo, retorno previsível

ROI em meses

Fracasso = problema

Inovação

Métrica de aprendizado: hipóteses validadas por trimestre

Incerteza alta: a maioria das apostas falha, e tudo bem

Horizonte de 1~3 anos; financiado pela eficiência

Fracasso barato = dado; fracasso caro = má gestão

Gartner (2025): dos milhares de fornecedores que se dizem “agênticos”, ~130 são reais. O resto é “agent washing” — chatbot com crachá novo.

Air Canada: quando a alucinação vira passivo jurídico

O caso

- Passageiro compra passagem para o funeral da avó; o chatbot informa que a tarifa de luto pode ser pedida até 90 dias após o voo
- A política real exigia solicitação antes da viagem — o chatbot alucinou uma regra
- No tribunal, a defesa alegou que o chatbot seria “uma entidade legal separada, responsável pelos próprios atos”
- O juiz rejeitou: a empresa responde por toda informação em seu site, venha de página estática ou de chatbot — e criou precedente



Para o seu produto:

- IA na frente do cliente = responsabilidade da empresa
- RAG com fontes verificáveis + limites do que o bot pode afirmar
- LGPD e revisão jurídica desde o desenho, não depois do incidente

Enquanto isso, dentro da sua empresa: a IA sombra

90%+

das organizações têm funcionários usando IA pessoal no trabalho

MIT, global (2025)

47,4%

dos profissionais brasileiros usam IA sem aprovação oficial

Abiacom/Brazil Panels (jan/2026)

40%


das empresas, apenas, têm assinatura corporativa de IA

MIT (2025)

Governança != de proibir. É dar o caminho seguro antes que o inseguro vire hábito.

A onda está começando agora

Empresas que usam IA no Brasil (%) — Cetic.br, TIC Empresas



72%

das empresas brasileiras ainda estão em estágio iniciante ou experimental de IA (Abiacom, 2026)

42%

relatam uso transformador de IA: acima da média global de 34% (Deloitte, State of AI 2026)

Quase tudo ainda está por construir. Aproveite essa chance!!!

Plano Brasileiro de Inteligência Artificial (PBIA)

IA para o Bem de Todos

R\$ 23B

Investimentos até 2028

Coordenado pelo MCTI

Objetivos Centrais

- **Desenvolvimento:** Impulsionar a inovação tecnológica nacional.
- **Soberania Digital:** Reduzir a dependência externa e proteger dados.
- **Uso Ético e Inclusivo:** Garantir que a IA beneficie a todos de forma justa.

01

Infraestrutura e PD&I

Supercomputação e fomento à pesquisa científica avançada.

02

Difusão na Economia

Integração da tecnologia nas cadeias produtivas e empresas.

03

Serviços Públicos

Melhoria da saúde, educação e governança com soluções de IA.

04

Capacitação

Formação de talentos e alfabetização digital para o novo mercado.

05

Apoio ao Processo

Uso ético, regulação justa e segurança cibernética.

Um plano estratégico de investimentos públicos e privados para posicionar o Brasil na fronteira global da tecnologia.

3 problemas reais. Apliquem as 5 perguntas.

1



Hospital

Quer reduzir faltas em consultas (no-show), que custam caro e desorganizam a agenda. Tem 5 anos de histórico de agendamentos.

2



E-commerce

Quer responder automaticamente dúvidas de clientes sobre a política de trocas e devoluções, hoje afogando o SAC.

3



Indústria

Quer detectar peças com defeito visual na esteira de produção, hoje inspecionadas por amostragem manual.

Mandem no chat: técnica recomendada + primeira pergunta que vocês fariam ao cliente →

O raciocínio importa mais que a resposta

1 • Hospital (no-show)

- Saída: categoria (vai faltar?) → classificação supervisionada
- Dados: 5 anos rotulados de graça (compareceu/faltou)
- Baseline antes do modelo: regra simples — 'faltou 2x seguidas?'
- Custo de errar: moderado → ação barata (lembrete via app/WhatsApp)

2 • E-commerce (trocas)

- Saída: texto/conversa → LLM + RAG na política oficial
- Guardrails: o bot só afirma o que está no documento
- Lembra da Air Canada? Alucinação aqui é passivo jurídico
- Baseline: uma boa página de FAQ resolve metade do volume

3 • Indústria (defeitos)

- Saída: categoria em imagem → visão computacional supervisionada
- Dados: fotos rotuladas — provavelmente precisa coletar primeiro
- Custo de errar: alto → humano revisa os casos incertos
- Lembra do McDonald's? Piloto em 1 linha, não na fábrica toda

Reparem: em nenhum caso a resposta começou pela técnica. Começou pela saída, pelos dados e pelo custo de errar.

O roadmap de 4 passos

01



Diagnosticque

Dados e processos: o que existe, onde dói, o que a LGPD exige

02



Priorize

Impacto x viabilidade: passe cada candidato pelas 5 perguntas do funil

03



Piloto pequeno

Métrica de NEGÓCIO definida antes, prazo curto, baseline simples como régua

04



Escale

Monitoramento, drift, humano no processo e freio de emergência

Cada passo desarma um dos casos de hoje: Klarna (métrica errada), McDonald's (piloto certo), Zillow (sem monitoramento), Air Canada (sem guardrails).

A CAUSA RAIZ

Por que empresas com dinheiro e dados falham em ML?

Porque tratam um problema de **abordagem** como se fosse um problema de **tecnologia**.

01

Defina o problema certo

Problema certo antes do modelo bonito: às vezes a resposta é um SQL

02

Alicerces sólidos

Dados e LGPD são o alicerce, não o detalhe

03

Métricas de negócio

Foco no negócio desde o dia zero; lembre-se de que a média esconde a distribuição

04

Comece pequeno

Piloto barato, escala monitorada e humano no processo

05

Financie a inovação

Eficiência bem feita financia o crescimento. Esse é o ciclo



Faça sua pergunta

|Digite sua pergunta...

Referências

MIT NANDA

The GenAI Divide: State of AI in Business 2025 (95% dos pilotos; US\$ 30–40 bi; shadow AI)
[cobertura: fortune.com, 18/08/2025](https://fortune.com/2025/08/18/genai-divide/)

Gartner

Press release, 25/06/2025 (>40% dos projetos agênticos cancelados até 2027; "agent washing")

gartner.com/en/newsroom

Cetic.br / NIC.br

Pesquisa TIC Empresas 2025, 16ª ed., jun/2026 (adoção de IA: 13%→17%; grandes: 38%→50%)

<https://cetic.br/pt/noticia/uso-de-inteligencia-artificial-por-empresas-brasileiras-avanca-e-atinge-17-aponta-pesquisa-do-cetic-br/>

Abiacom / Brazil Panels

Pesquisa de maturidade em IA, jan/2026 (72% em estágio inicial; 47,4% shadow AI)

<https://abiacom.org/estudos/>

Deloitte AI Institute

State of AI in the Enterprise 2026 (42% uso transformador no Brasil vs. 34% global)

deloitte.com/br

Sculley et al.

Hidden Technical Debt in ML Systems, NeurIPS 2015

papers.nips.cc

Klarna

Anúncio oficial Klarna/OpenAI (fev/2024); declarações estratégicas e operacionais do CEO à Bloomberg (2025)

[via entrepreneur.com](https://entrepreneur.com), fintechweekly.com

McDonald's + IBM

Encerramento do piloto de drive-thru automatizado por voz com inteligência artificial, jul/2024

[via AP / Yahoo Finance](https://apnews.com)

Zillow

Resultados trimestrais consolidados Zillow Group, Q3/nov 2021; análise de falha algorítmica Stanford GSB

gsb.stanford.edu

Air Canada

Decisão judicial Moffatt v. Air Canada, Civil Resolution Tribunal (BC, Canadá), fev/2024

[em PT-BR: exame.com](https://exame.com), tecnoblog.net, conjur.com.br

Material Complementar

Teste seus conhecimentos

Aponte a câmera do seu celular para o QR Code ao lado ou clique no link abaixo para acessar o quiz da aula

Link direto para o quiz:

feliperafael.github.io/quiz-aula-machine-learning-business-strategies/

